Sprint 4 Data Analytics

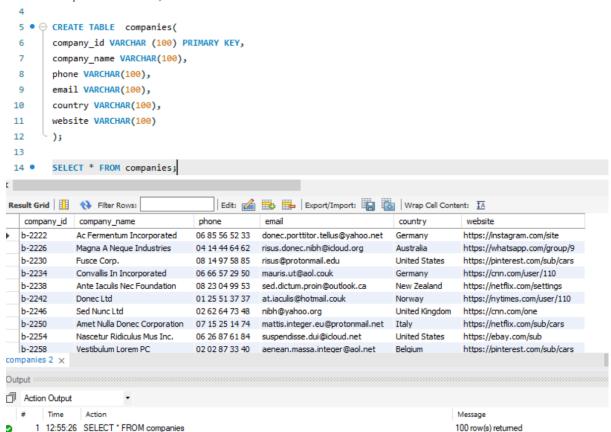
Descarga los archivos CSV, estúdialos y diseña una base de datos con un esquema de estrella que contenga, al menos 4 mesas de las cuales puedas realizar las siguientes consultas:

En primer lugar, creamos una nueva base de datos a la cual llamaremos "sprint4":



Comenzamos a crear tablas:

 En la primera tabla "companies" se han insertado los datos a través de Import Wizard, con el resto de tablas fue de manera manual.

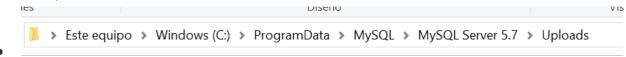


• Creación y carga tabla "products":

```
-- tabla products: id, product_name, price, colour, weight, warehouse_id. 100 rows. Import manual code ok.
9 • ⊖ CREATE TABLE products (
        id VARCHAR(100) PRIMARY KEY,
0
1
         product_name VARCHAR(100),
2
         price VARCHAR(100),
         colour VARCHAR(100),
4
         weight DECIMAL(5,2),
         warehouse_id VARCHAR(100)
5
    );
6
    LOAD DATA INFILE 'C:/ProgramData/MySQL/MySQL Server 5.7/Uploads/products.csv'
     INTO TABLE products
     FIELDS TERMINATED BY ','
     ENCLOSED BY '"'
     LINES TERMINATED BY '\n'
     IGNORE 1 ROWS;
```

Comandos:

Con LOAD DATA INFILE '...': Especificamos la ubicación completa del archivo CSV que cargamos en la tabla "products". En este punto había tenido una serie de problemas para cargar el código manual en mysql. La ubicación de la descarga de los recursos no se veía, por un simple problema de vista de docs ocultos. Finalmente, la ubicación correcta es:



A través de INTO TABLE products se nos indica que los datos del archivo CSV deben ser insertados en la tabla "products".

FIELDS TERMINATED BY ',': Define que los campos en el archivo CSV están separados por la coma (,).

ENCLOSED BY "": Indica que los valores de los campos en el archivo CSV están encerrados entre comillas dobles (").

LINES TERMINATED BY '\n': Especifica que las líneas en el archivo CSV están terminadas por un salto de línea (\n).

IGNORE 1 ROWS: Instruye a MySQL para que ignore la primera fila del archivo CSV. Esta opción es sumamente útil cuando la primera fila contiene encabezados de columna y no datos reales que se deben insertar en la tabla. Si no se aplica nos dará error.

• Creación y carga de la tabla "credit_cards":

```
• 

○ CREATE TABLE credit_cards (
        id VARCHAR(100) PRIMARY KEY,
        user_id VARCHAR(100),
        iban VARCHAR(100),
        pan VARCHAR(100),
        pin VARCHAR(100),
        cvv VARCHAR(100),
        track1 VARCHAR(150),
        track2 VARCHAR(150),
        expiring_date VARCHAR(100)
     );
3
J • LOAD DATA INFILE 'C:/ProgramData/MySQL/MySQL Server 5.7/Uploads/credit_cards.csv'
3
    INTO TABLE credit_cards
    FIELDS TERMINATED BY ','
L
2
    ENCLOSED BY '"'
    LINES TERMINATED BY '\n'
3
    IGNORE 1 ROWS;
1
```

• Creación y carga de las tablas "users":

```
■ CREATE TABLE users_ca (

id VARCHAR(100) PRIMARY KEY,

name VARCHAR(100),

surname VARCHAR(100),

phone VARCHAR(100),

email VARCHAR(100),

birth_date VARCHAR(100),

country VARCHAR(100),

city VARCHAR(100),

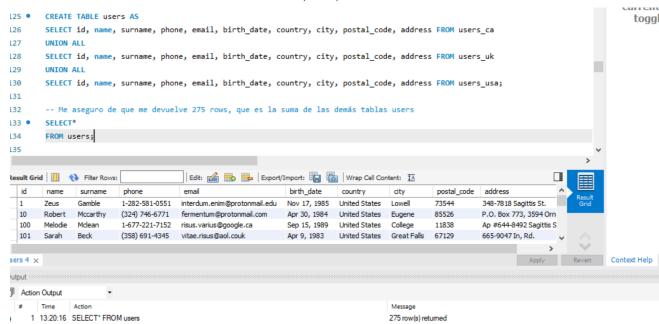
postal_code VARCHAR(100),

address VARCHAR(100)

7 IGNORE 1 RONS;
```

```
. • ⊝ CREATE TABLE users uk (
      id VARCHAR(100) PRIMARY KEY,
      name VARCHAR(100),
      surname VARCHAR(100),
      phone VARCHAR(100),
       email VARCHAR(100),
       birth_date VARCHAR(100),
       country VARCHAR(100),
       city VARCHAR(100),
        postal_code VARCHAR(100),
1
        address VARCHAR(100)
   LOAD DATA INFILE 'C:/ProgramData/MySQL/MySQL Server 5.7/Uploads/users_uk.csv'
  INTO TABLE users uk
   FIELDS TERMINATED BY ','
   ENCLOSED BY """
   LINES TERMINATED BY '\r\n'
   IGNORE 1 ROWS;
01 • ○ CREATE TABLE users_usa (
           id VARCHAR(100) PRIMARY KEY,
32
           name VARCHAR(100),
23
94
           surname VARCHAR(100),
           phone VARCHAR(100),
25
           email VARCHAR(100),
96
97
           birth_date VARCHAR(100),
           country VARCHAR(100),
86
            city VARCHAR(100),
99
            postal_code VARCHAR(100),
10
            address VARCHAR(100)
11
     (( ا
12
     LOAD DATA INFILE 'C:/ProgramData/MySQL/MySQL Server 5.7/Uploads/users usa.csv'
     INTO TABLE users_usa
     FIELDS TERMINATED BY ','
     ENCLOSED BY '"'
     LINES TERMINATED by '\r\n'
     IGNORE 1 ROWS;
```

Una vez creadas las 3 tablas users:ca. uk, usa, las unificamos:.



Creamos la nueva tabla y a través del comando UNION ALL combinamos los resultados de las consultas SELECT de las tres tablas (users_ca, users_uk, y users_usa), incluyendo todas las filas, incluso si hay duplicados.

Las columnas seleccionadas para la nueva tabla son las mismas en todas las tablas originales: id, name, surname, phone, email, birth_date, country, city, postal_code, address. Nos queda una tabla con 275 rows (la suma de las 3).

Después, procedemos a eliminar las tablas users ca, uk y usa que ya no nos sirven:

```
-- Procedo a eliminar las tablas que ya no me sirven:
```

- DROP TABLE users_ca;
- DROP TABLE users uk;
- DROP TABLE users_usa;

Finalmente, la dotamos de una PK:

```
-- doy una PK
```

ALTER TABLE users ADD PRIMARY KEY (id); • Creación de la tabla de hechos "transactions":

```
7 ● ○ CREATE TABLE transactions (
         id VARCHAR(100) PRIMARY KEY,
        card_id VARCHAR(100),
9
0
         business_id VARCHAR(100),
         timestamp DATETIME,
1
        amount DECIMAL(6,2),
2
         declined VARCHAR(100),
3
        product_ids VARCHAR(100),
         user id VARCHAR(100),
5
          lat FLOAT,
6
          longitude FLOAT
7
    ٠);
8
9

    LOAD DATA INFILE 'C:/ProgramData/MySQL/MySQL Server 5.7/Uploads/transactions.csv'

    INTO TABLE transactions
    FIELDS TERMINATED BY ';'
   ENCLOSED BY '"'
    LINES TERMINATED BY '\n'
    IGNORE 1 ROWS;
```

Ahora añadimos las fk para poder enlazar las tablas

```
-- quiero añadir las fk
-- para card_id

ALTER TABLE transactions
ADD CONSTRAINT fk_card
FOREIGN KEY (card_id) REFERENCES credit_cards(id);
-- para user_id

ALTER TABLE transactions
ADD CONSTRAINT fk_user_transaction
FOREIGN KEY (user_id) REFERENCES users(id);
-- para companies

ALTER TABLE transactions
ADD CONSTRAINT fk_business
FOREIGN KEY (business_id) REFERENCES companies(company_id);
```

En primer lugar, se añade una Foreign Key "fk_card" que vincula la columna "card_id" de "transactions" con la columna "id" de la tabla "credit_cards". Luego, se crea la Foreign Key "fk_user_transaction" que enlaza la columna "user_id" de "transactions" con la columna "id" de la tabla "users". Finalmente, se añade la Foreign Key "fk_business" que conecta la columna "business_id" de "transactions" con la columna "company_id" de la tabla "companies.

Ahora debemos hacer una tabla intermedia entre "products" y "transactions".

```
≥ ○ ○ CREATE TABLE transaction products (
             transaction id VARCHAR(255),
3
ļ
              product_id VARCHAR (100),
            FOREIGN KEY (transaction_id) REFERENCES transactions(id),
            FOREIGN KEY (product id) REFERENCES products(id));
Y añadimos:
      INSERT INTO transaction products (transaction id, product id)
     SELECT
9
0
        id AS transaction id.
        TRIM(SUBSTRING_INDEX(SUBSTRING_INDEX(REPLACE(product_ids, ' ', ''), ',', numbers.n), ',', -1)) AS product_id
2
    FROM
        (SELECT 1 AS n UNION ALL SELECT 2 UNION ALL SELECT 3 UNION ALL SELECT 4 UNION ALL SELECT 5 UNION ALL SELECT 6
3
        UNION ALL SELECT 7 UNION ALL SELECT 8 UNION ALL SELECT 9 UNION ALL SELECT 10) numbers
4
         INNER JOIN transactions ON CHAR_LENGTH(REPLACE(product_ids, ' ', ''))
5
        - CHAR_LENGTH(REPLACE(REPLACE(product_ids, ' ', ''), ',', '')) >= numbers.n - 1;
```

Con INSERT INTO transaction_products (transaction_id, product_id): indicamos que se insertarán datos en las columnas transaction_id y product_id de la tabla transaction_products.

Después, con SELECT id AS transaction_id, TRIM(SUBSTRING_INDEX(SUBSTRING_INDEX(REPLACE(product_ids, ' ', ''), ',', numbers.n), ',', -1)) AS product_id:

seleccionamos dos valores para cada fila a insertar en transaction_products. Primero, selecciona "id" de la tabla "transactions" y lo alias como "transaction_id". Segundo, usamos una serie de funciones para extraer los "product_id" de una lista separada por comas en la columna "product_ids" de "transactions".

REPLACE(product_ids, ' ', ''): Elimina los espacios en blanco de "product_ids". SUBSTRING_INDEX(REPLACE(product_ids, ' ', ''), ',', numbers.n): Obtiene la subcadena de "product_ids" hasta la enésima coma.

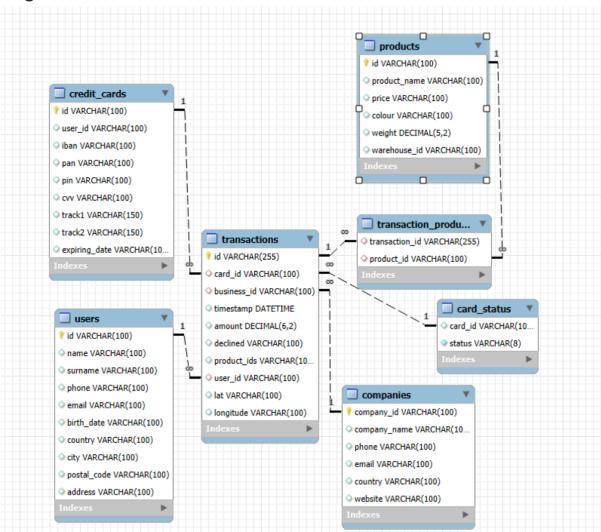
SUBSTRING_INDEX(..., ',', -1): Obtiene el elemento después de la última coma de la subcadena obtenida anteriormente.

TRIM(...): Elimina cualquier espacio en blanco restante del "product_id". FROM (SELECT 1 AS N UNION ALL SELECT 2 UNION ALL SELECT 3 UNION ALL SELECT 4 UNION ALL SELECT 5 UNION ALL SELECT 6 UNION ALL SELECT 7 UNION ALL SELECT 8 UNION ALL SELECT 9 UNION ALL SELECT 10) numbers: Esta subconsulta genera una tabla temporal llamada numbers con una sola columna n que contiene los números del 1 al 10. Esto se usa para crear un rango de índices para extraer múltiples "product_id" de "product_ids".

INNER JOIN transactions ON CHAR_LENGTH(REPLACE(product_ids, ' ', '')) - CHAR_LENGTH(REPLACE(REPLACE(product_ids, ' ', ''), ', '')) >= numbers.n - 1: La condición del INNER JOIN asegura que solo se seleccionen las transacciones que tienen suficientes productos en "product_ids" para el índice actual numbers n. Calcula la diferencia en la longitud de "product_ids" antes y después de eliminar las comas, lo que indica la cantidad de productos, y verifica si esto es mayor o igual que el índice actual numbers n.

El código divide las listas de "product_ids" en la tabla "transactions" y crea nuevas filas en la tabla "transaction_products" para cada combinación de "transaction_id" y "product_id", asegurando que cada producto de una transacción se registre correctamente en la tabla de relación.

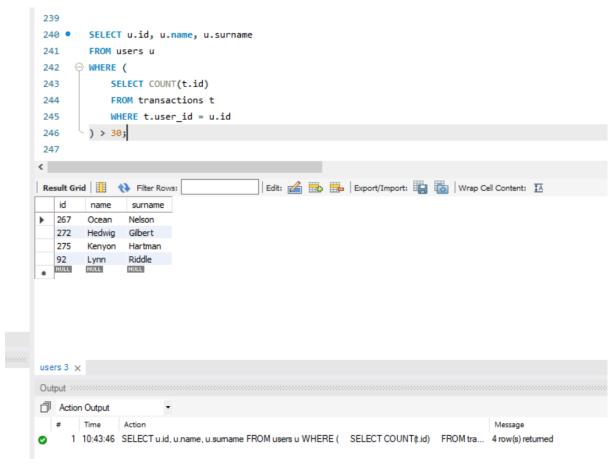
Diagrama



Nivell 1

- Ejercicio 1

Realiza una subconsulta que muestre todos los usuarios con más de 30 transacciones utilizando al menos 2 tablas.



En esta query usamos la subconsulta SELECT COUNT(t.id) FROM transactions t WHERE t.user_id = u.id, así podemos contar el número de transacciones para cada usuario. El resultado de la subconsulta se compara con 30. Solo los usuarios con más de 30 transacciones se seleccionan.

- Ejercicio 2

Muestra la media de amount por IBAN de las tarjetas de crédito a la compañía Donec Ltd, utiliza al menos 2 tablas.

```
-- Ejercicio 2. Nivel 1.

7 • SELECT cc.iban, c.company_name, ROUND(AVG(t.amount), 2) AS media

3 FROM credit_cards cc

9 JOIN transactions t ON cc.id = t.card_id

9 JOIN companies c ON t.business_id = c.company_id

1 WHERE c.company_name = 'Donec Ltd'

2 GROUP BY cc.iban, c.company_name;

| Export: | Wrap Cell Content: | W
```



Para este ejercicio usamos el comando SELECT para elegir las columnas "cc.iban", "c.company_name" y el cálculo ROUND(AVG(t.amount), 2) AS media. Luego, utilizamos FROM para especificar la tabla principal "credit_cards" con el alias cc. A continuación, usamos JOIN para realizar uniones internas: primero entre "credit_cards" y "transactions" con" cc.id = t.card_id", y luego entre "transactions" y "companies" con "t.business_id = c.company_id". La cláusula WHERE filtra las filas para incluir solo aquellas donde "c.company_name" es 'Donec Ltd'. Finalmente, con GROUP BY agrupamos los resultados por "cc.iban" y "c.company_name", permitiendo calcular el promedio de los montos de las transacciones para cada combinación única de IBAN y nombre de compañía.

Nivell 2

Crea una nueva tabla que refleje el estado de las tarjetas de crédito basado en si las últimas tres transacciones fueron declinadas y genera la siguiente consulta:

Creamos una tabla temporal para almacenar las filas con el número de transacción

```
46 • CREATE TEMPORARY TABLE TempTransacciones AS
47
      SELECT
          card id,
49
          declined,
          @row_num := IF(@prev_card_id = card_id, @row_num + 1, 1) AS Rank_Transaccion,
50
          @prev_card_id := card_id
51
52
     FROM
          (SELECT @row_num := 0, @prev_card_id := NULL) AS vars,
53
54 ⊖
          (SELECT card_id, declined
55
           FROM transactions
           ORDER BY card_id, timestamp DESC) AS T;
56
```

La tabla temporal "TempTransacciones" se utiliza para calcular el número de transacción y determinar el estado de las tarjetas de crédito. Normalmente, se usaría la función ROW_NUMBER() que permitiría numerar las filas de un conjunto de resultados en base a un orden específico, pero al tener una versión anterior de MySql_debo usar las variables de usuario (@row_num y @prev_card_id) para asignar un número de transacción secuencial (Rank_Transaccion) a cada registro de transacción, agrupados por card_id y ordenados por timestamp descendente.

Una vez asignado el número de transacción a cada registro utilizando la tabla temporal TempTransacciones, se puede utilizar esta información para determinar el estado de cada tarjeta de crédito (card_id) en la tabla card_status. Esto se hace agrupando los resultados por card_id y aplicando una lógica condicional (CASE WHEN) para definir si una tarjeta está 'Activa', 'Inactiva' o cualquier otro estado basado en las condiciones de negocio establecidas.

Eficiencia y temporalidad: La tabla TempTransacciones se crea como una tabla temporal (CREATE TEMPORARY TABLE) porque su objetivo es ser utilizada temporalmente dentro de la sesión de MySQL actual. Una vez que se completa el cálculo del estado de las tarjetas y se crea la tabla card_status, la tabla temporal TempTransacciones ya no es necesaria y se elimina automáticamente al finalizar la sesión de MySQL. Esto ayuda a mantener la limpieza y evitar la acumulación de datos temporales innecesarios en la base de datos.

Ahora, creamos la tabla card_status usando los datos de la tabla temporal:

```
CREATE TABLE card status AS
259
260
        SELECT
261
             card_id,
262
      \Theta
             CASE
                 WHEN COUNT(*) < 3 THEN 'Activa'
263
                 WHEN SUM(declined) = 3 THEN 'Inactiva'
264
                 ELSE 'Activa'
265
266
             END AS status
267
        FROM TempTransacciones
        WHERE Rank Transaccion <= 3
268
        GROUP BY card id;
269
```

CREATE TABLE card_status AS: Aquí creamos la tabla card_status que almacenará el estado de las tarjetas de crédito basado en los datos de la tabla temporal TempTransacciones.

SELECT card_id, CASE WHEN COUNT(*) < 3 THEN 'Activa' WHEN SUM(declined) = 3 THEN 'Inactiva' ELSE 'Activa' END AS status FROM TempTransacciones WHERE Rank_Transaccion <= 3 GROUP BY card_id: Esta consulta calcula el estado (status) de cada tarjeta de crédito (card_id) utilizando la tabla temporal TempTransacciones. Se utiliza una estructura CASE para determinar si una tarjeta está 'Activa' si tiene menos de tres transacciones, 'Inactiva' si todas sus transacciones fueron rechazadas (declined = 1), o de lo contrario, se considera 'Activa'. Se agrupa por card_id y se filtran solo las primeras tres transacciones más recientes (Rank_Transaccion <= 3).

```
271 •
        CREATE INDEX idx card id ON transactions(card id);
272 •
        ALTER TABLE card status
        ADD INDEX idx_card_id (card_id);
273
274
275
        ALTER TABLE transactions
        ADD CONSTRAINT fk card id
276
        FOREIGN KEY (card_id)
277
278
        REFERENCES card_status(card_id);
279
```

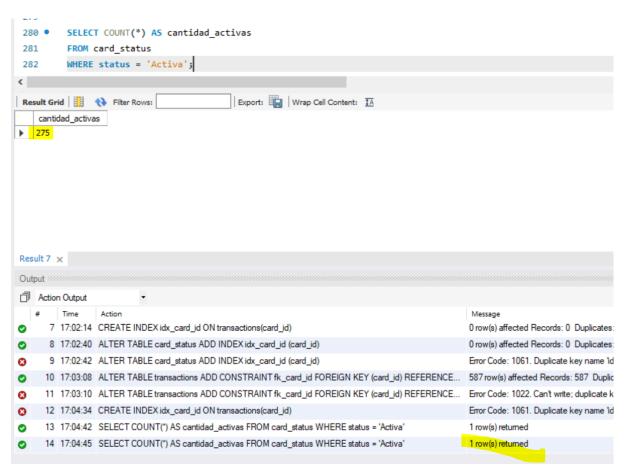
CREATE INDEX idx_card_id ON transactions(card_id): Se crea un índice en la columna card_id de la tabla transactions, lo que mejora la eficiencia de las consultas que involucran esta columna.

ALTER TABLE card_status ADD INDEX idx_card_id (card_id): Se añade un índice en la columna card_id de la tabla card_status, lo que optimiza las búsquedas basadas en esta columna.

ALTER TABLE transactions ADD CONSTRAINT fk_card_id FOREIGN KEY (card_id) REFERENCES card_status(card_id): Se establece una clave foránea en la tabla transactions que referencia la columna card_id de card_status. Esto garantiza la integridad referencial, asegurando que cada card_id en transactions esté asociado correctamente con su estado correspondiente en card_status.

- Ejercicio 1

¿Cuántas tarjetas están activas?



Con la consulta SELECT COUNT(*) AS cantidad_activas calculamos el número total de registros que cumplen con la condición establecida. En este caso, el alias "cantidad_activas".

El comando FROM card_status especifica la tabla desde la cual se obtienen los datos para contar las filas.

La cláusula WHERE status = 'Activa' actúa como un filtro que restringe los resultados a solo aquellas filas donde el valor de la columna status es igual a 'Activa'.

Finalmente, COUNT(*) es la función de agregación que cuenta todas las filas que cumplen con el criterio especificado en la cláusula WHERE. En este contexto, cuenta el número de tarjetas que están marcadas como activas ('Activa') en la tabla card_status.